


Capstone-Projekt: Eine Analyse zur Weinqualität

**Analyse der
Weinqualität mit
Python, Power BI
und Excel**





Titel: Eine Analyse zur Weinqualität

Name: Ahmadi, Seyed Mohammad Hossein

Datum: 1 April 2025



Einleitung

Ziel des Projekts und Verwendete Tools

Ziel des Projekts:

- Analyse der Faktoren, die die Weinqualität beeinflussen.
- Vorhersage der Weinqualität mit verschiedenen Tools (Python, Power BI, Excel).

Verwendete Tools:

- **Python:** Pandas, Matplotlib, Seaborn, Scikit-Learn für Machine Learning (Random Forest, XGBoost).
- **Power BI:** Interaktive Dashboards und Matrix Visualization für die Datenanalyse.
- **Excel:** Pivot Tables und Diagramme zur grundlegenden Analyse.

Modellvergleich:

- **Beste Ergebnisse:** Random Forest Modell mit einem R^2 von 0.463 und MSE von 0.299.

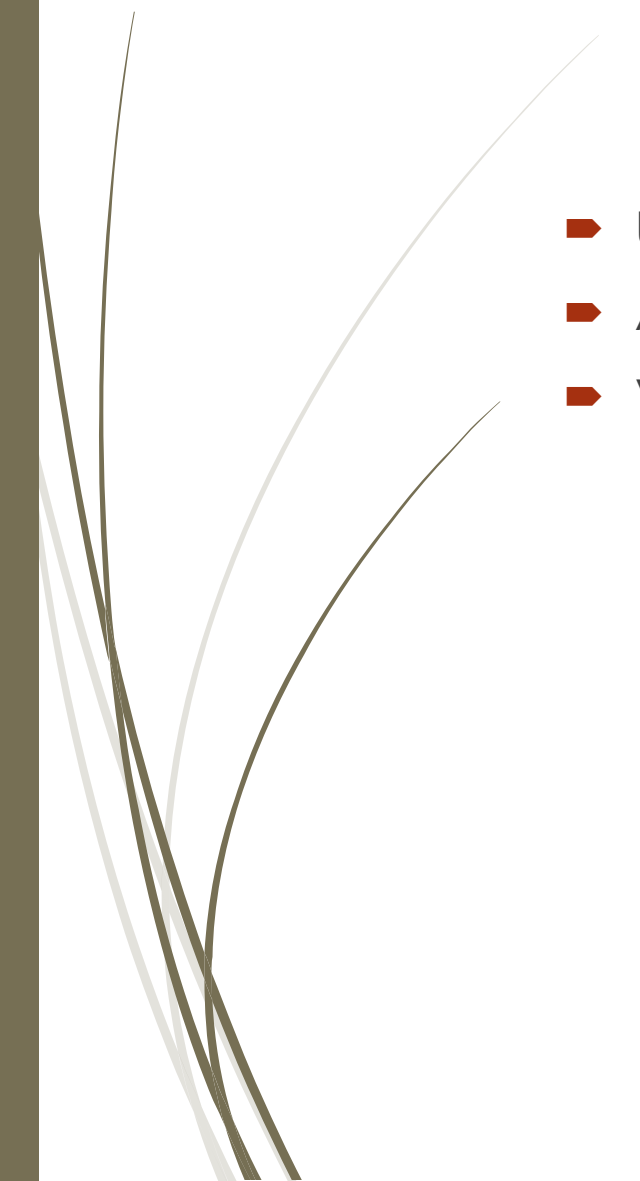
Datensatzbeschreibung

- **Datensatz:** Enthält verschiedene chemische Eigenschaften von Weinen
- **Anzahl der Einträge:** 1143
- **Anzahl der Merkmale:** 13
- **Wichtigste Features:** Alkoholgehalt, pH-Wert, Zitronensäure etc.





1. Ziel des Projekts

- Untersuchung der Faktoren, die die Weinqualität beeinflussen.
 - Analyse der Merkmale wie Alkoholgehalt, pH-Wert, Säuregehalt etc.
 - Vorhersage der Weinqualität mit Python und optional Power BI und Excel.
- 

2. Verwendete Tools



- Haupttool: Python
- Pandas: Zur Datenmanipulation und -bereinigung.
- Matplotlib & Seaborn: Für die Visualisierung von Daten (z. B. Histogramme, Streudiagramme, Korrelationsmatrix).
- Scikit-Learn: Zur Implementierung und Evaluierung von Machine Learning-Modellen.
- XGBoost & Random Forest: Modelle für die Vorhersage der Weinqualität.
- Zusätzliche Tools: Power BI und Excel
- Power BI: Interaktive Dashboards und Visualisierungen.
- Excel: Pivot-Tabellen und Diagramme zur grundlegenden Analyse.

3. Datenvorbereitung und Analys (Pythonschwerpunkt)

- Daten einlesen und erste Inspektion mit Pandas.
- Statistische Zusammenfassung der Daten: Mittelwert, Standardabweichung etc.
- Visualisierung:
 - Histogramme für die Verteilung der Merkmale.
 - Korrelationsmatrix zur Analyse der Beziehungen zwischen den Variablen.
- Datenaufbereitung:
 - Entfernung von Ausreißern.
 - Normalisierung und Standardisierung der Daten.
 - Aufteilung der Daten in Trainings- und Testdaten (80% - 20%).

[3]:

```
# مرحله 3: بررسی داده‌ها و اطلاعات اولیه
# Schritt 3: Daten betrachten und grundlegende Informationen erhalten
print(df.head()) # اولین 5 ردیف داده‌ها را نمایش می‌دهد
# Zeigt die ersten 5 Zeilen der Daten an
print(df.info()) # اطلاعات کلی در مورد ستون‌ها
# Zeigt grundlegende Informationen zu den Spalten an
```

	fixed acidity	volatile acidity	citric acid	residual sugar	chlorides
0	7.4	0.70	0.00	1.9	0.07
1	7.8	0.88	0.00	2.6	0.09
2	7.8	0.76	0.04	2.3	0.09
3	11.2	0.28	0.56	1.9	0.07
4	7.4	0.70	0.00	1.9	0.07

	free sulfur dioxide	total sulfur dioxide	density	pH	sulphates
0	11.0	34.0	0.9978	3.51	0.56
1	25.0	67.0	0.9968	3.20	0.68
2	15.0	54.0	0.9970	3.26	0.65
3	17.0	60.0	0.9980	3.16	0.58
4	11.0	34.0	0.9978	3.51	0.56

	alcohol	quality	Id
0	9.4	5	0
1	9.8	5	1
2	9.8	5	2
3	9.8	6	3
4	9.4	5	4

```
<class 'pandas.core.frame.DataFrame'>
```

```
RangeIndex: 1143 entries, 0 to 1142
```

```
Data columns (total 13 columns):
```

#	Column	Non-Null Count	Dtype
0	fixed acidity	1143 non-null	float64
1	volatile acidity	1143 non-null	float64
2	citric acid	1143 non-null	float64
3	residual sugar	1143 non-null	float64
4	chlorides	1143 non-null	float64
5	free sulfur dioxide	1143 non-null	float64
6	total sulfur dioxide	1143 non-null	float64
7	density	1143 non-null	float64
8	pH	1143 non-null	float64
9	sulphates	1143 non-null	float64
10	alcohol	1143 non-null	float64
11	quality	1143 non-null	int64
12	Id	1143 non-null	int64

```
dtypes: float64(11), int64(2)
```

```
memory usage: 116.2 KB
```

```
None
```

[11]:

```
# مرحله 5: تقسیم داده‌ها به داده‌های آموزشی و آزمایشی
# Schritt 5: Daten in Trainings- und Testdaten aufteilen
X = df.drop(['quality', 'Id'], axis=1) # ویژگی‌ها
# Merkmale (ohne die Spalten "quality" und "Id")
y = df['quality'] # هدف (کیفیت شراب)
# Ziel (Weinqualität)
```

```
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42) # تقسیم داده‌ها به 80% آموزش و 20% تست
# Aufteilung der Daten in 80% Training und 20% Test
```

[13]:

```
# مرحله 6: ساخت مدل رگرسیون خطی
# Schritt 6: Lineares Regressionsmodell erstellen
model = LinearRegression() # ایجاد مدل رگرسیون خطی
# Erstellen eines linearen Regressionsmodells
model.fit(X_train, y_train) # آموزش مدل بر روی داده‌های آموزشی
# Modell mit den Trainingsdaten trainieren
```

[13]:

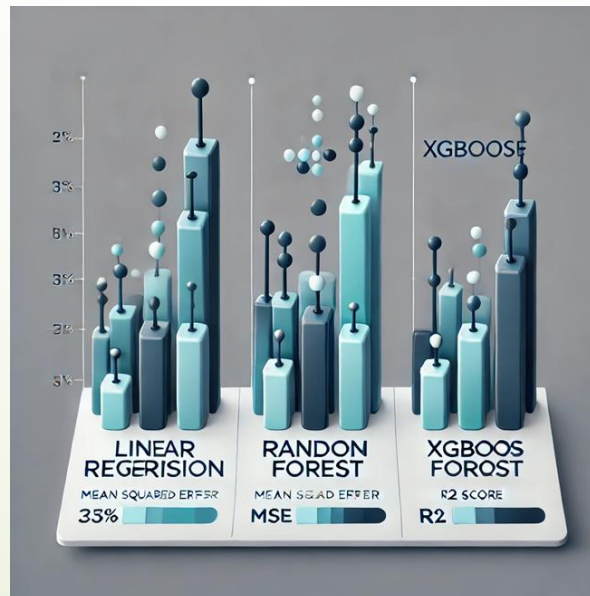
```
LinearRegression
```

[15]:

```
# مرحله 7: پیش‌بینی بر روی داده‌های آزمایشی
# Schritt 7: Vorhersagen für Testdaten machen
y_pred = model.predict(X_test) # پیش‌بینی کیفیت شراب با استفاده از مدل
# Vorhersage der Weinqualität mit dem Modell
```


4. Modellvergleich und Ergebnisse

- Vergleich der Modelle:
- Lineare Regression: $MSE = 0.38$, $R^2 = 0.32$
- Random Forest: $MSE = 0.30$, $R^2 = 0.46$
- XGBoost: $MSE = 0.37$, $R^2 = 0.34$
- Bestes Modell: Random Forest zeigte die besten Ergebnisse mit einem R^2 von 0.463 und einem MSE von 0.299.



[21]:

```
# وارد کردن کتابخانه‌های XGBoost
import xgboost as xgb # XGBoost / XGBoost-Modell importieren

# ایجاد مدل XGBoost
xgb_model = xgb.XGBRegressor(n_estimators=100, random_state=42) # تنظیمات / Modell konfigurieren

# آموزش مدل روی داده‌های آموزشی
xgb_model.fit(X_train, y_train) # Modell mit Trainingsdaten trainieren

# پیش‌بینی با استفاده از مدل آموزش‌دیده
y_pred_xgb = xgb_model.predict(X_test) # Vorhersagen mit Testdaten machen

# ارزیابی مدل
mse_xgb = mean_squared_error(y_test, y_pred_xgb) # Mittleren quadratischen Fehler berechnen
r2_xgb = r2_score(y_test, y_pred_xgb) # Bestimmtheitsmaß berechnen

print(f"Mean Squared Error (XGBoost): {mse_xgb}") # Mittleren quadratischen Fehler anzeigen
print(f"R² Score (XGBoost): {r2_xgb}") # Bestimmtheitsmaß anzeigen
```

```
Mean Squared Error (XGBoost): 0.36556705832481384
R² Score (XGBoost): 0.3430641293525696
```

[23]:

```
# وارد کردن کتابخانه‌های شبکه عصبی
from sklearn.neural_network import MLPRegressor # Multi-Layer Perceptron (MLP) Modell importieren

# ایجاد مدل شبکه عصبی
mlp_model = MLPRegressor(hidden_layer_sizes=(50,), max_iter=1000, random_state=42) # تنظیمات / Modell konfigurieren

# آموزش مدل روی داده‌های آموزشی
mlp_model.fit(X_train, y_train) # Modell mit Trainingsdaten trainieren

# پیش‌بینی با استفاده از مدل آموزش‌دیده
y_pred_mlp = mlp_model.predict(X_test) # Vorhersagen mit Testdaten machen

# ارزیابی مدل
mse_mlp = mean_squared_error(y_test, y_pred_mlp) # Mittleren quadratischen Fehler berechnen
r2_mlp = r2_score(y_test, y_pred_mlp) # Bestimmtheitsmaß berechnen

print(f"Mean Squared Error (Neural Network): {mse_mlp}") # Mittleren quadratischen Fehler anzeigen
print(f"R² Score (Neural Network): {r2_mlp}") # Bestimmtheitsmaß anzeigen
```

```
Mean Squared Error (Neural Network): 0.36774858168102
```

[25]:

```
# 1. رگرسیون خطی (Linear Regression)
from sklearn.linear_model import LinearRegression
from sklearn.metrics import mean_squared_error, r2_score

# ایجاد مدل رگرسیون خطی
lr_model = LinearRegression()
lr_model.fit(X_train, y_train)

# پیش‌بینی با مدل رگرسیون خطی
y_pred_lr = lr_model.predict(X_test)

# برای رگرسیون خطی R² محاسبه میانگین مربعات خطا و
mse_lr = mean_squared_error(y_test, y_pred_lr)
r2_lr = r2_score(y_test, y_pred_lr)

# 2. جنگل تصادفی (Random Forest)
from sklearn.ensemble import RandomForestRegressor

# ایجاد مدل جنگل تصادفی
rf_model = RandomForestRegressor(n_estimators=100, random_state=42)
rf_model.fit(X_train, y_train)

# پیش‌بینی با مدل جنگل تصادفی
y_pred_rf = rf_model.predict(X_test)

# برای جنگل تصادفی R² محاسبه میانگین مربعات خطا و
mse_rf = mean_squared_error(y_test, y_pred_rf)
r2_rf = r2_score(y_test, y_pred_rf)

# 3. XGBoost
import xgboost as xgb

# ایجاد مدل XGBoost
xgb_model = xgb.XGBRegressor(n_estimators=100, random_state=42)
xgb_model.fit(X_train, y_train)

# پیش‌بینی با مدل XGBoost
y_pred_xgb = xgb_model.predict(X_test)

# برای XGBoost R² محاسبه میانگین مربعات خطا و
mse_xgb = mean_squared_error(y_test, y_pred_xgb)
r2_xgb = r2_score(y_test, y_pred_xgb)


# 4. نمایش نتایج
print("Mean Squared Error (Linear Regression):", mse_lr)
print("R² Score (Linear Regression):", r2_lr)
print("Mean Squared Error (Random Forest):", mse_rf)
print("R² Score (Random Forest):", r2_rf)
print("Mean Squared Error (XGBoost):", mse_xgb)
print("R² Score (XGBoost):", r2_xgb)
```

```
Mean Squared Error (Linear Regression): 0.38003245026277527
R² Score (Linear Regression): 0.3170693672733127
Mean Squared Error (Random Forest): 0.2989554585152839
R² Score (Random Forest): 0.462767349736139
Mean Squared Error (XGBoost): 0.36556705832481384
R² Score (XGBoost): 0.3430641293525696
```

5. Ergebnisse und Erkenntnisse

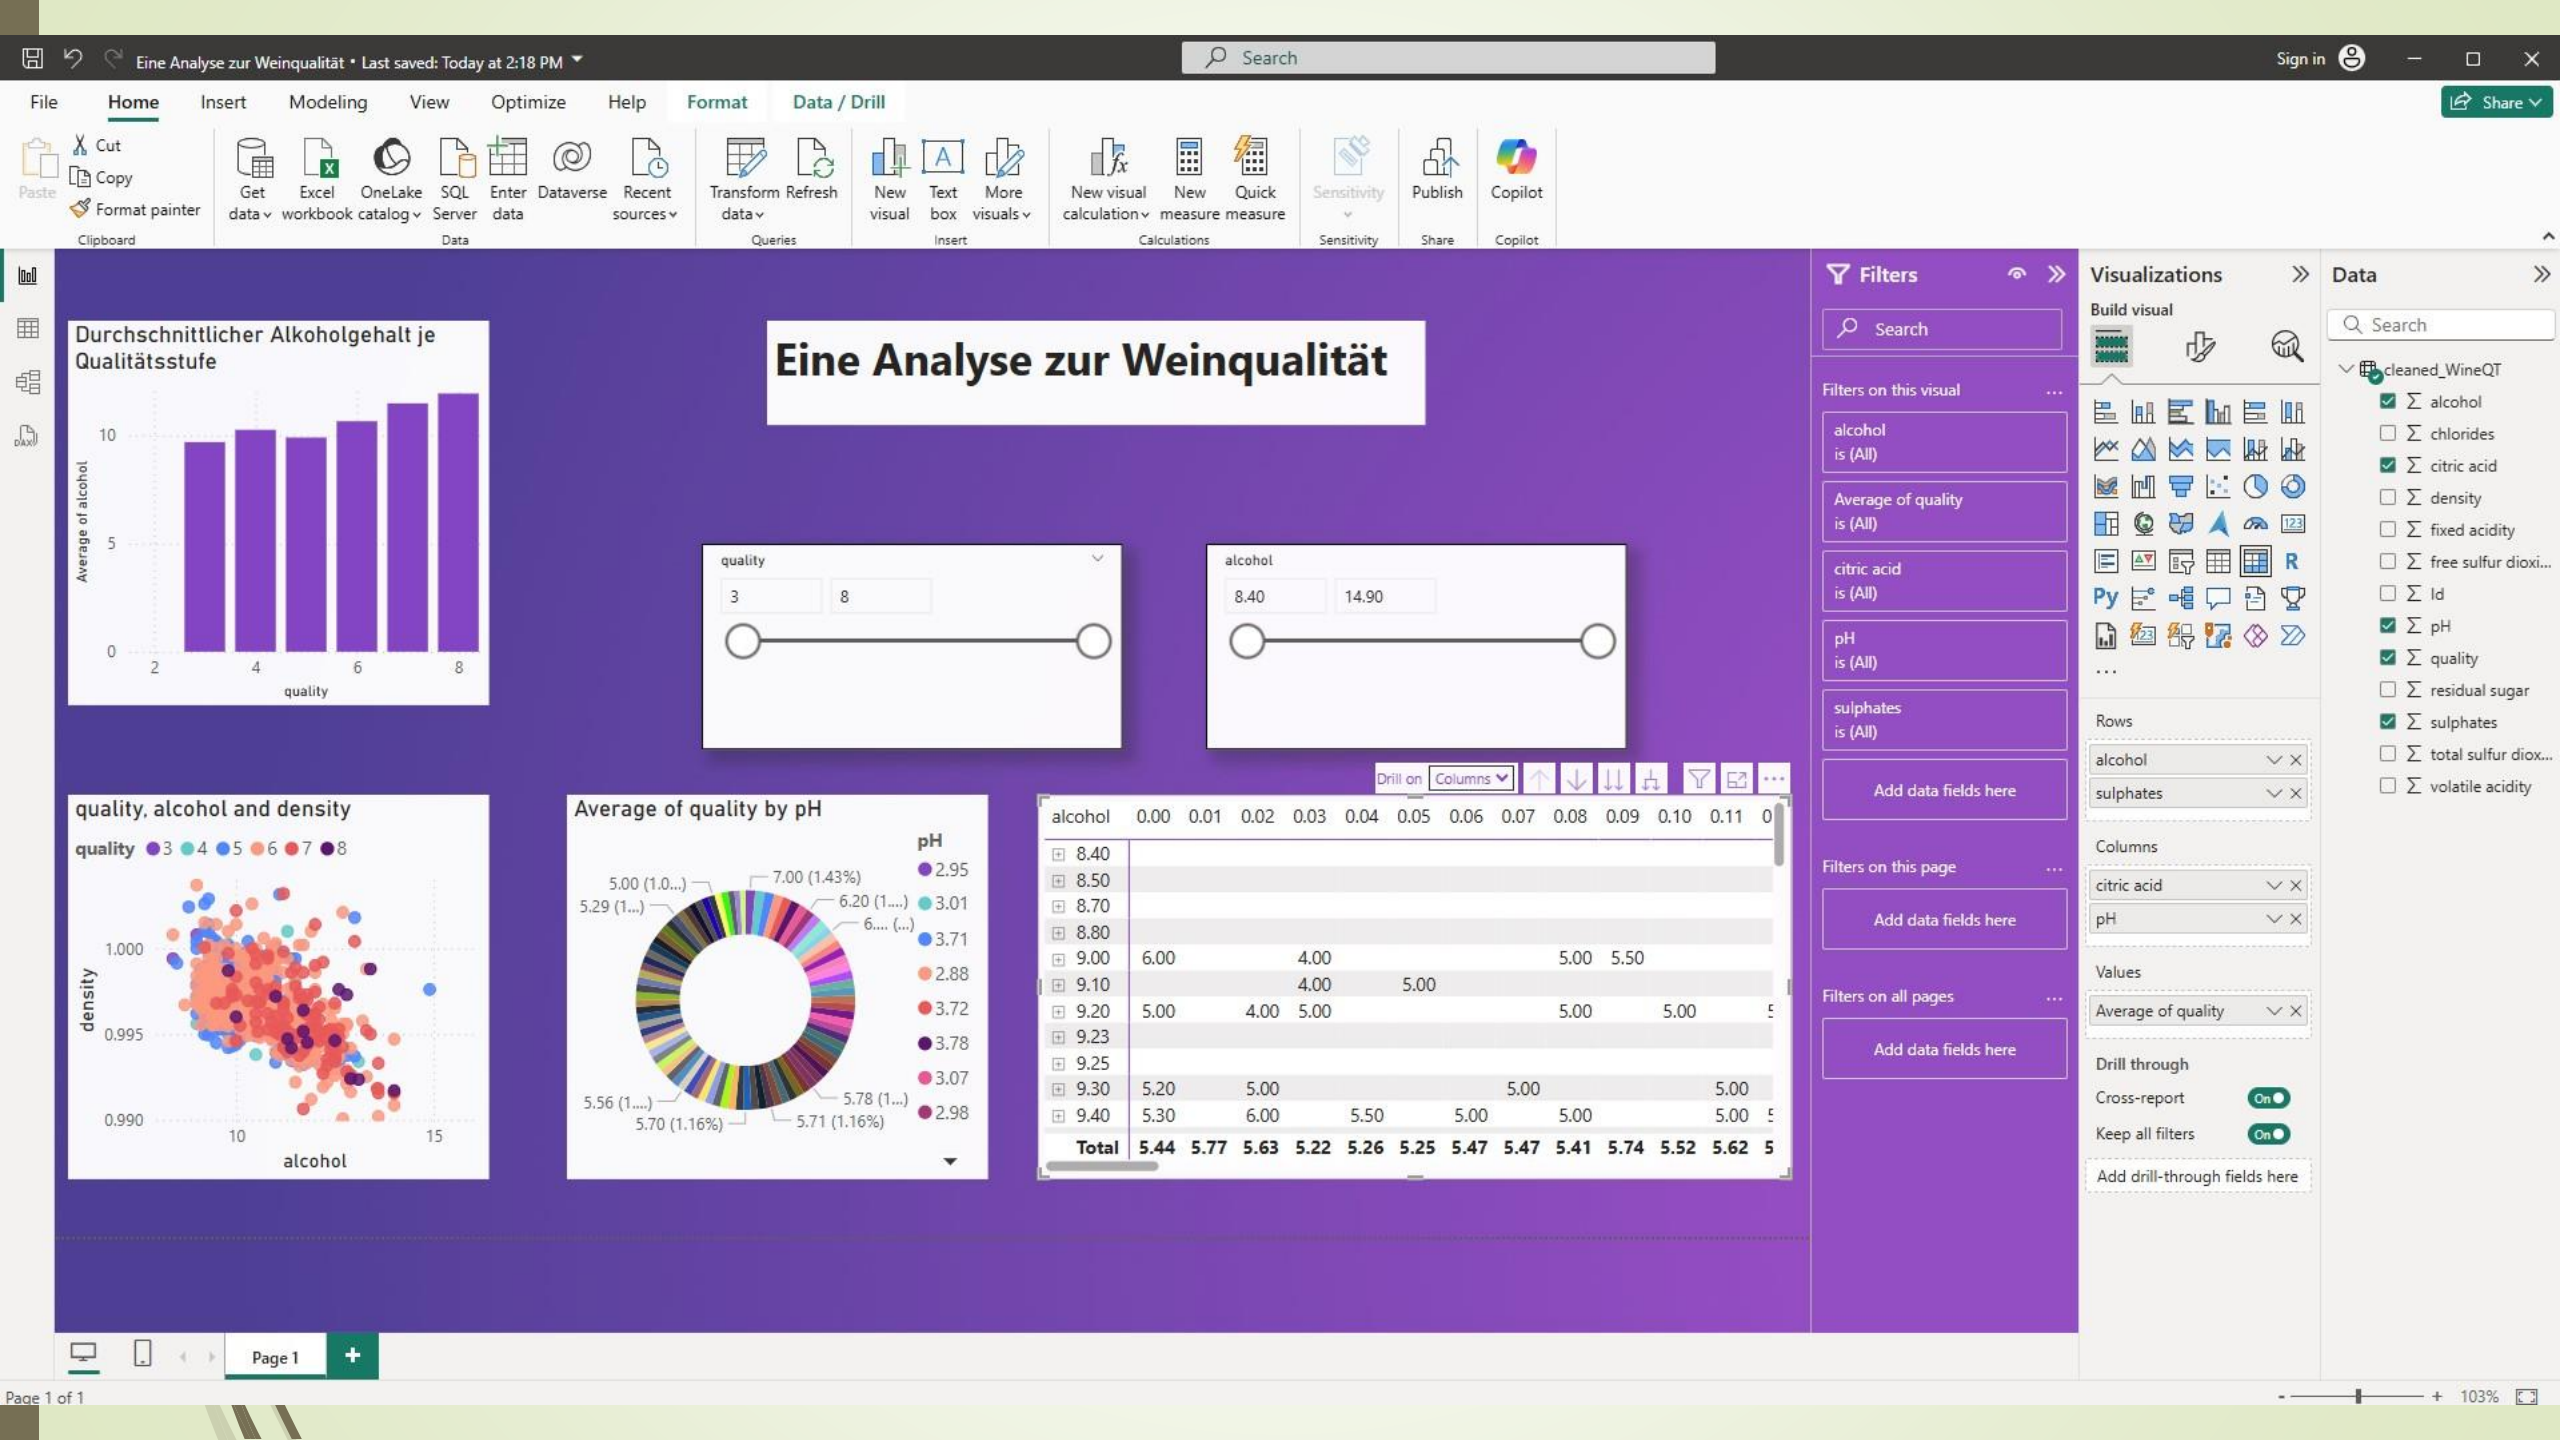
- Ergebnisse:
- Das Random Forest-Modell hat die besten Vorhersagen erzielt.
- Wichtige Merkmale, die die Weinqualität beeinflussen: Alkoholgehalt, Säuregehalt, pH-Wert.
- Schlussfolgerungen:
- Das Random Forest-Modell liefert robuste Vorhersagen und ist für die Weinqualitätsvorhersage am geeignetsten.

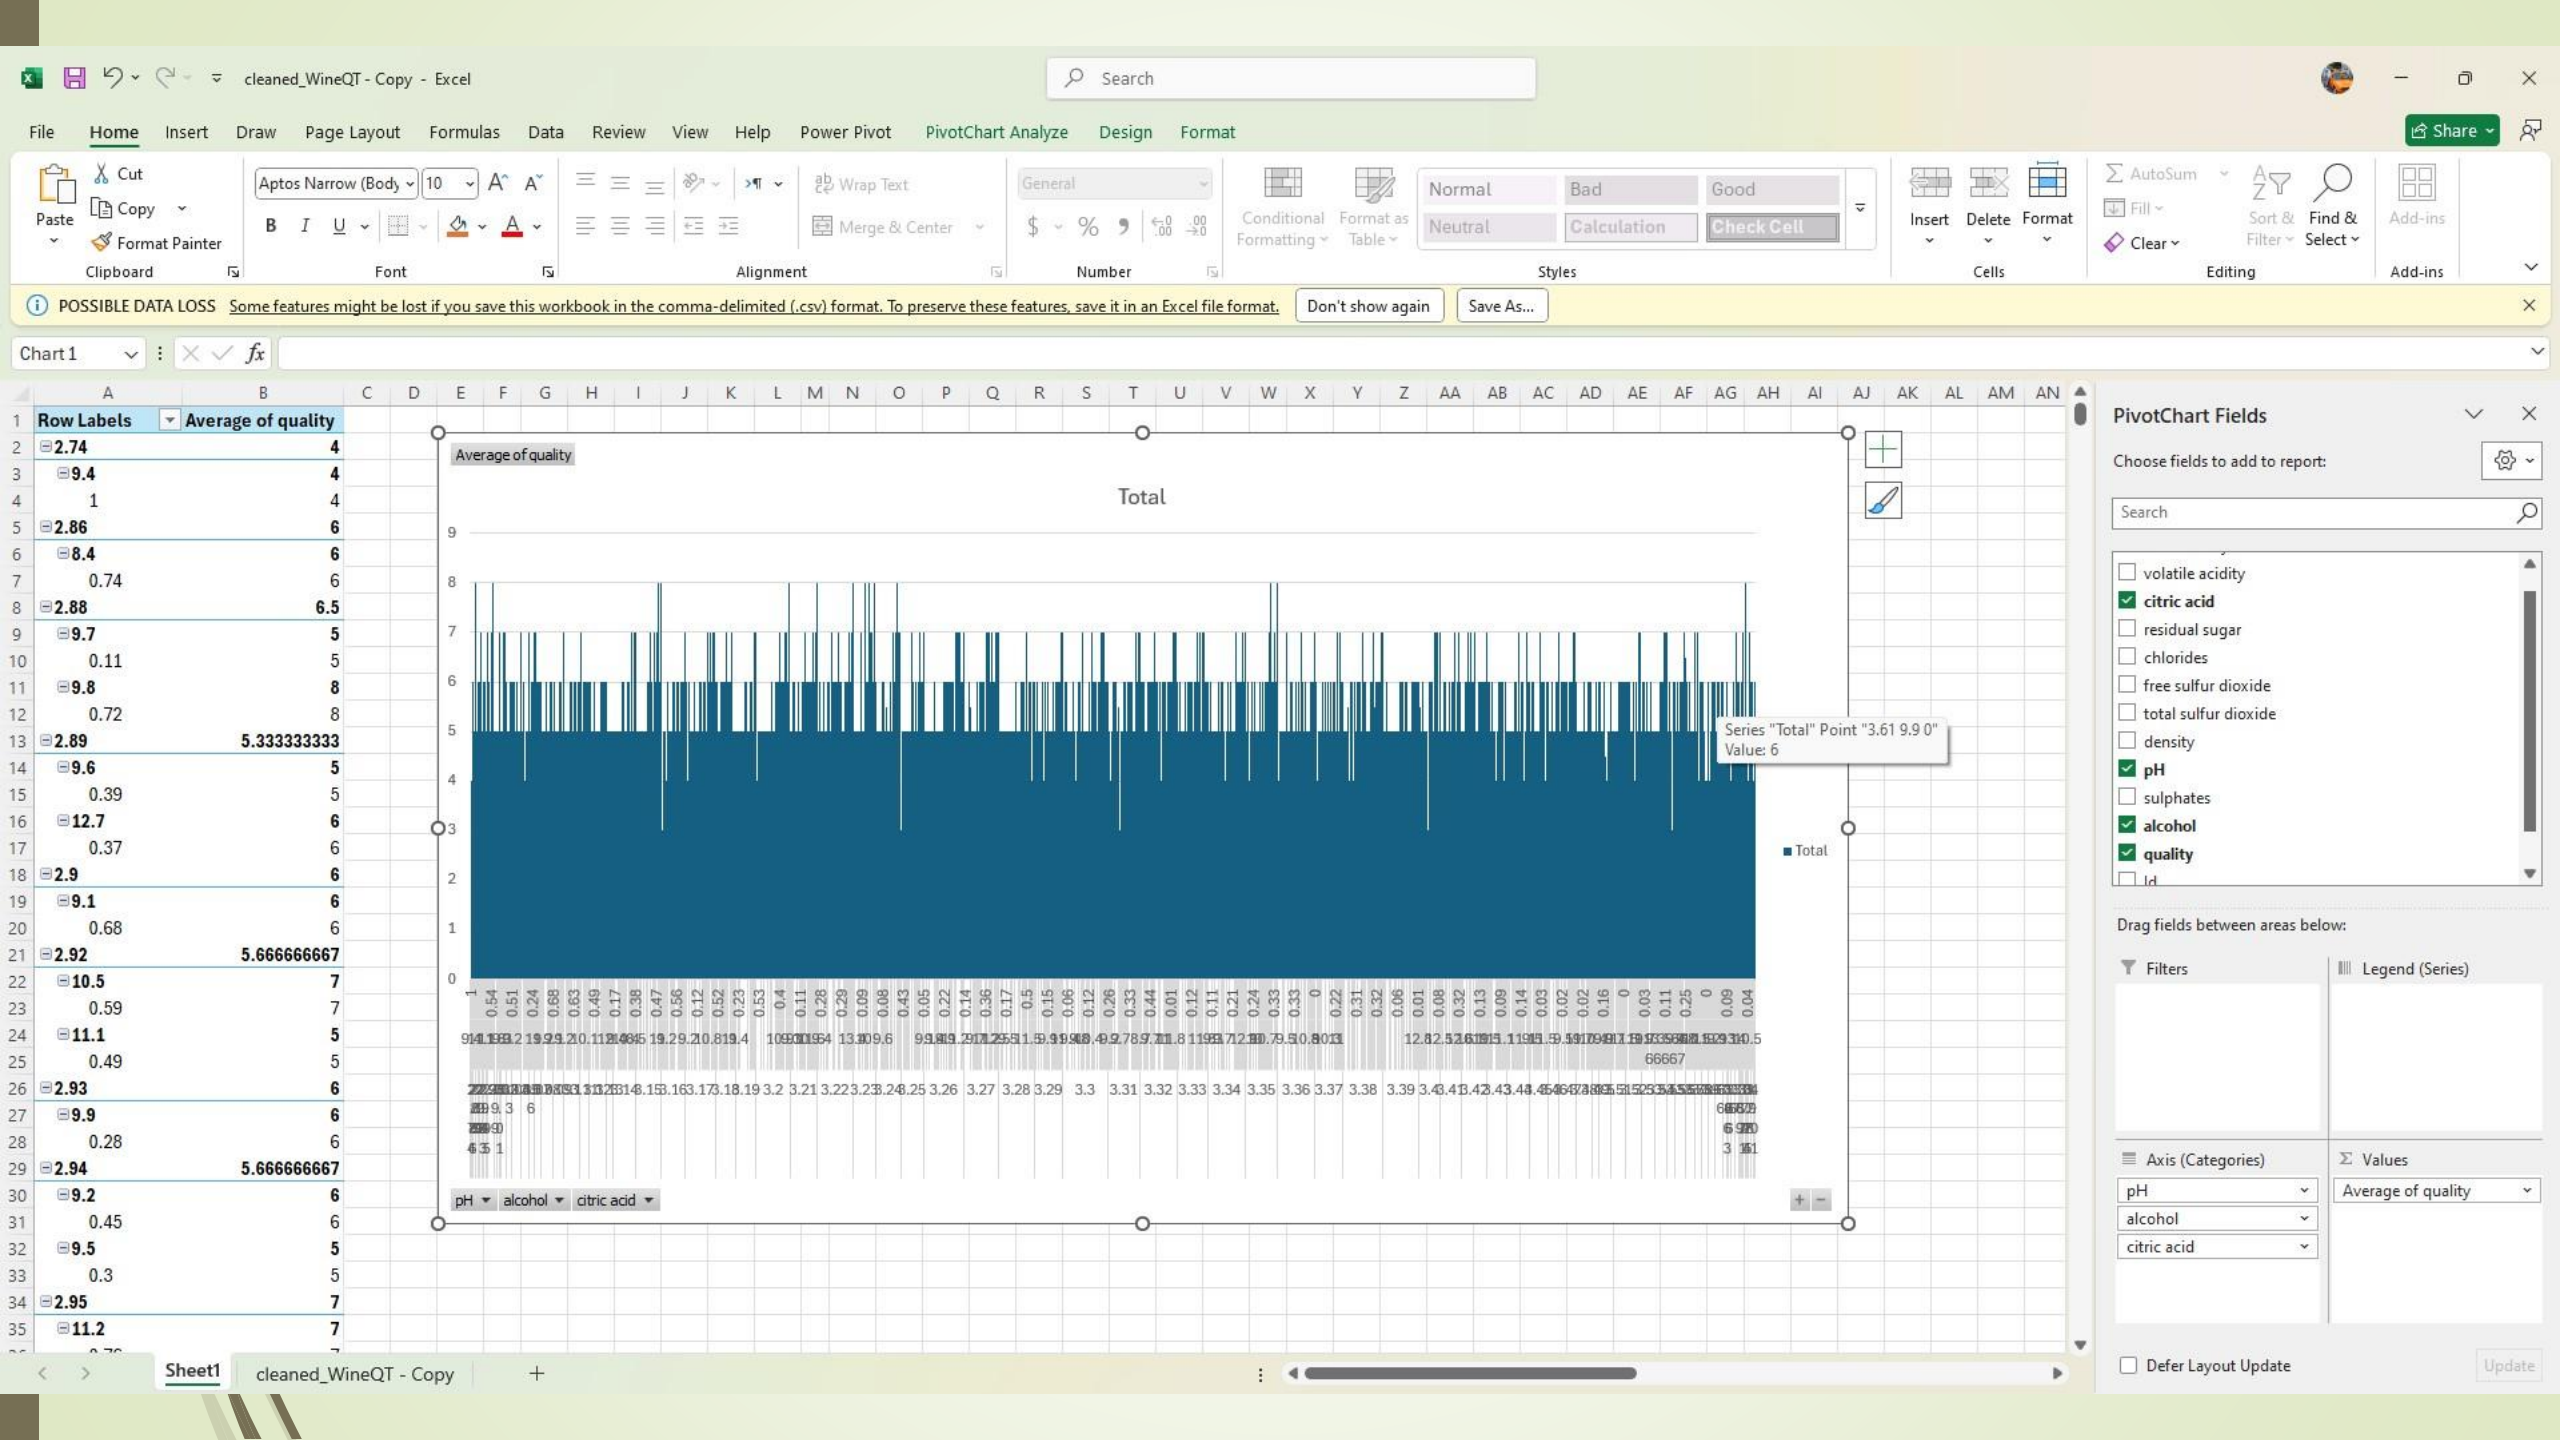

```
[4]: # مرحله 4: تجزیه و تحلیل داده‌ها
# Schritt 4: Daten analysieren
sns.heatmap(df.corr(), annot=True, cmap='coolwarm') # نقشه حرارتی برای بررسی همبستگی‌ها
# Heatmap zur Überprüfung der Korrelationen
plt.show()
```




6. Visualisierungen


- Power BI:
- Interaktive Dashboards zur Analyse und Visualisierung von Zusammenhängen zwischen den Vari
- Verwendung von Balkendiagrammen, Streudiagrammen und Matrix Visualizations.
- Excel:
- Erstellung von Pivot-Tabellen zur Untersuchung von Datenzusammenhängen.
- Visualisierung durch Balken- und Streudiagramme.
- Python:
- Matplotlib & Seaborn für die Visualisierung der Datenverteilung und der Korrelationen.
- Erstellung von Histogrammen und Korrelationsmatrizen.







Save As...



Vielen Dank
für Ihre
Aufmerksamkeit!